서울특별시 공공자전거, 따릉이 대여 수 예측을 위한 탐색적 데이터 분석

Ksy_DataUnicorn

서울특별시 마포구 따릉이 데이터 EDA

결측값 대체 → 이상치 처리 → 상관 분석 → 파생변수 생성 → 데이터 시각화

데이터 전처리 및 탐색 시 유의사항

- 해당 도메인 및 프로젝트에 대한 이해 기반 문제 정의
- 분석 목적을 고려하여 머신러닝 모델을 왜곡할 우려가 있는 결측값 대체 및 이상치 처리
- 변수 간 관계 파악 및 분석에 용이한 새로운 변수 파생
- 숫자 또는 문자로 발견하기 어려운 패턴을 직관적으로 전달하기 위한 데이터 시각화

- 시간대 범주형 파생변수
- 극단적 대기오염물질 농도 논리형 파생변수

timeZone, atomosphere

따릉이 데이터 결측값 처리

데이터 분석 목적

- 서울특별시 마포구의 시간별 기상상황 및 따릉이 대여수 데이터
- 1시간 전 기상상황 데이터로 1시간 후 시간대의 따릉이 대여수 예측 목적의 데이터 분석

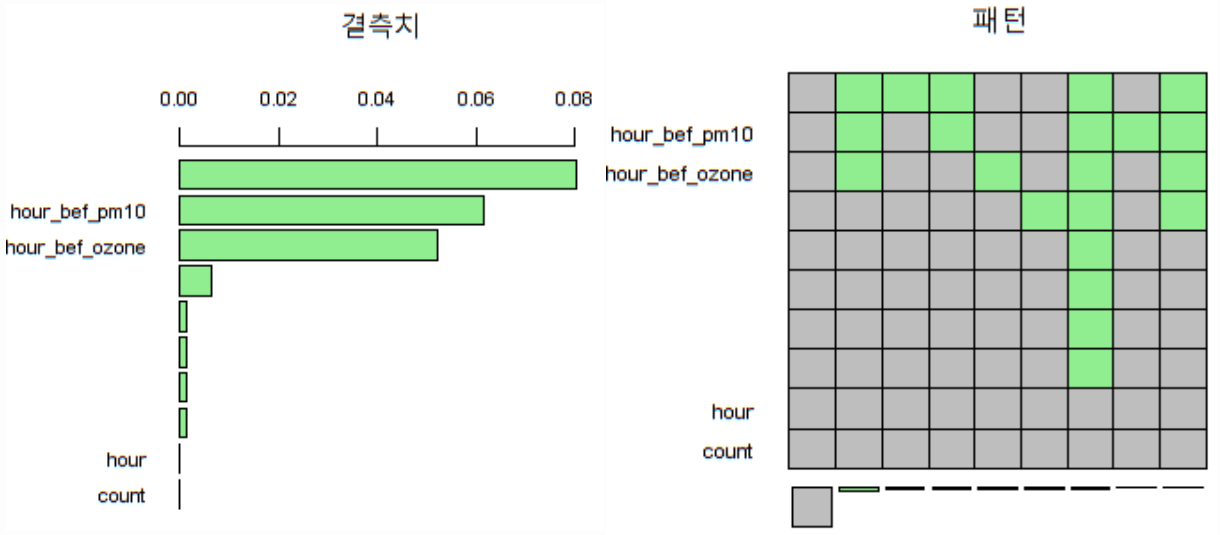

결측값 시각화 및 대체

- 결측값을 예측값으로 대체할 변수
  - **pm10**(117개) **pm2.5**(90개)
    결측값을 회귀식 추정하여 예측값으로 대체
  - **1시간 전 오존**(76개)
    결측값을 다중대체법(mice function)*에 따라 여러 모델 동시에 사용하는 앙상블 기법으로 예측한 값으로 대체
- 결측값이 발생하는 경우의 유형에 따라 처리 기준이 달라진다 (데이터 누락 | 0 | 무작위 발생)

*) Multiple Imputation by Chained Equations

따릉이 데이터 이상치 처리

이상치 시각화 및 처리

- 이상치 검출
  - **박스플롯**

    Q1 - 1.5 * IQR 이하 Q3 + 1.5 * IQR 이상

  - **표준정규분포를 이용한 두 값 사이의 확률에서 벗어난 확률변수**

    μ - 2.58 * σ 이하 μ + 2.58 * σ 이상

  - **쿡의 거리로 다중회귀식의 그래프 개형에 영향을 미치는 값**

    다중회귀모형에서 Cook's Distance 값(표준화된 잔차의 합) 확인

$$D_i = \frac{\sum_{j=1}^{n}(\hat{y}_j - \hat{y}_{j(i)})^2}{pMSE}$$

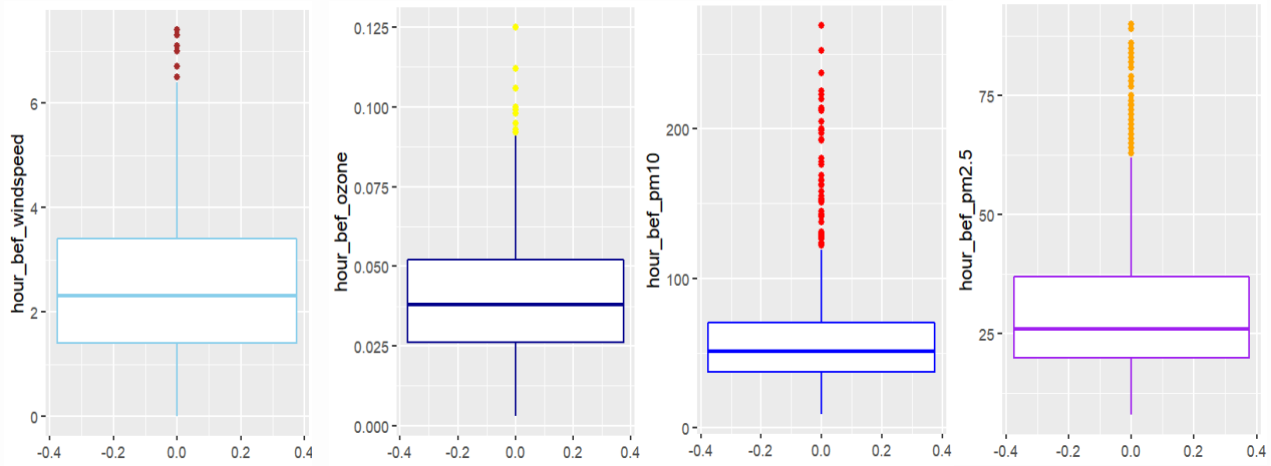

자연 발생적인 이상치로 판단되어 값에 대한 파악

- **풍속 변수의 이상치 존치 (예시)**

  오존 이상치, 풍속 이상치, 고온, 낮은 습도, 햇빛 : 저녁 시간대 자전거 280대 대여

  미세먼지 이상치, 풍속 이상치, 서늘한 기온, 낮은 습도, 햇빛 : 저녁 시간대 자전거 106대 대여

- **대기오염물질 농도(오존, 미세먼지 입자) 관련 변수의 이상치 여부 관련 파생변수 생성**

  이상치와 분리하여 시각화 및 모델링 가능

따릉이 데이터 이상치 처리

이상치 시각화 및 처리

- 이상치 검출 $D_i = \frac{\sum_{j=1}^{n}(\hat{y}_j - \hat{y}_{j(i)})^2}{pMSE}$

쿡의 거리로 다중회귀식의 그래프 개형에 영향을 미치는 값의 행 제거

```
Call:
lm(formula = count ~ hour_bef_temperature + hour_bef_windspeed +
    hour_bef_humidity + hour_bef_ozone + hour_bef_pm10, data = train)

Residuals:
     Min       1Q   Median       3Q      Max
-174.354  -41.626   -8.728   35.187  226.245

Coefficients:
                    Estimate Std. Error t value Pr(>|t|)
(Intercept)          8.25296   10.50492   0.786    0.432
hour_bef_temperature 6.56891    0.38108  17.238  < 2e-16 ***
hour_bef_windspeed  11.00362    1.38899   7.922 4.63e-15 ***
hour_bef_humidity   -0.62616    0.09385  -6.672 3.59e-11 ***
hour_bef_ozone     443.72757  106.01214   4.186 3.02e-05 ***
hour_bef_pm10       -0.37047    0.05105  -7.256 6.47e-13 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 59.68 on 1444 degrees of freedom
  (결측으로 인하여 9개의 관측치가 삭제되었습니다.)
Multiple R-squared:  0.4804,    Adjusted R-squared:  0.4786
F-statistic:   267 on 5 and 1444 DF,  p-value: < 2.2e-16
```

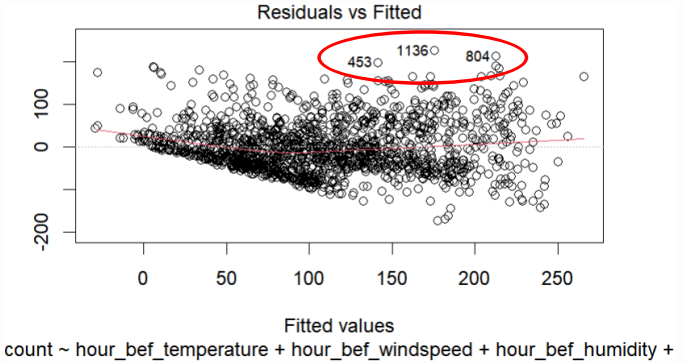

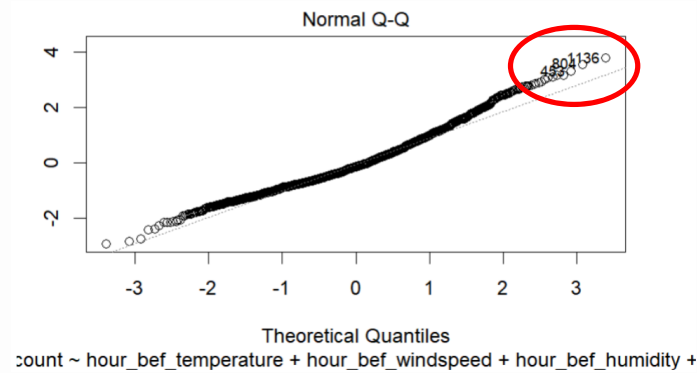

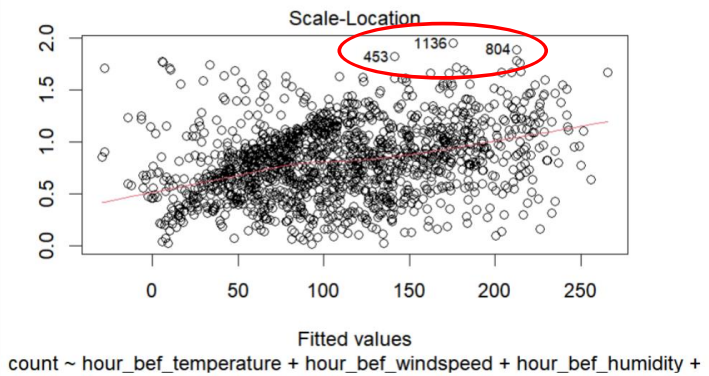

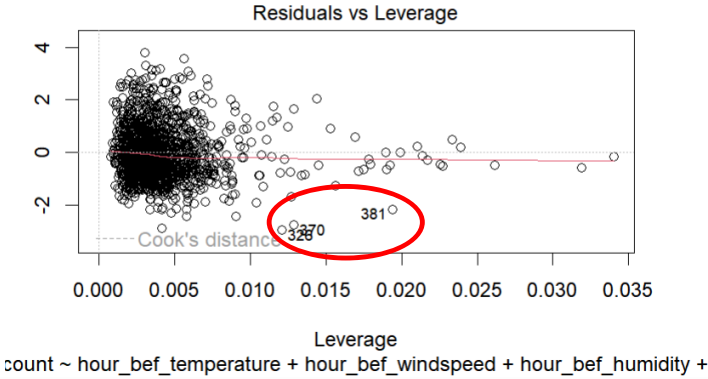

pm2.5는 2p-value > 0.05로 상관계수 추정치가 통계적으로 유의하지 않은 바 다중회귀식 추정 시 pm2.5 제거

따릉이 데이터 상관분석

변수 간 상관관계 분석

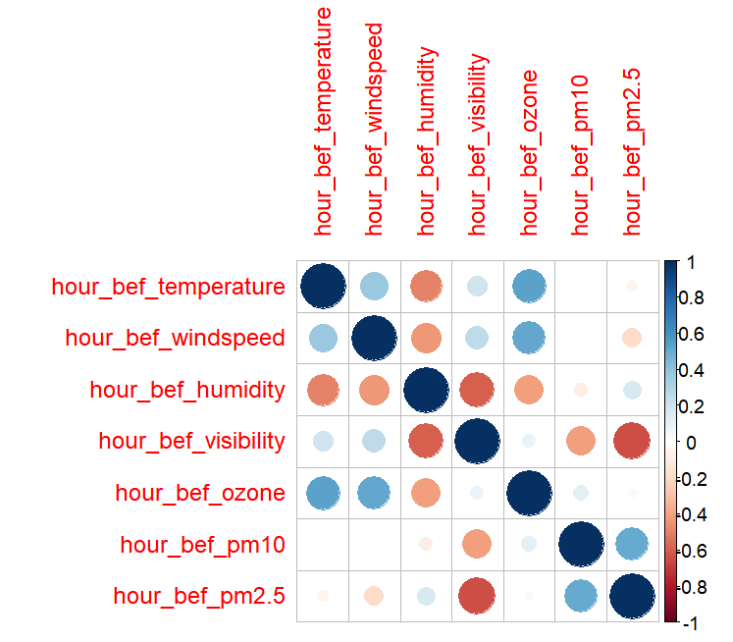

- temperature와 ozone 간 상관계수 r = 0.54
- windspeed와 temperature 간 상관계수 r = 0.38
- windspeed와 ozone 간 상관계수 r = 0.52
- pm10와 pm2.5 간 상관계수 r = 0.51
- humidity와 windspeed 상관계수 r = - 0.43

이상치 검출을 위해 추정할 다중회귀식의 독립변수 선택 (feature selection)

따릉이 데이터 파생변수 생성

시간(hour)에서 시간대(timeZone) 범주형 파생변수 생성

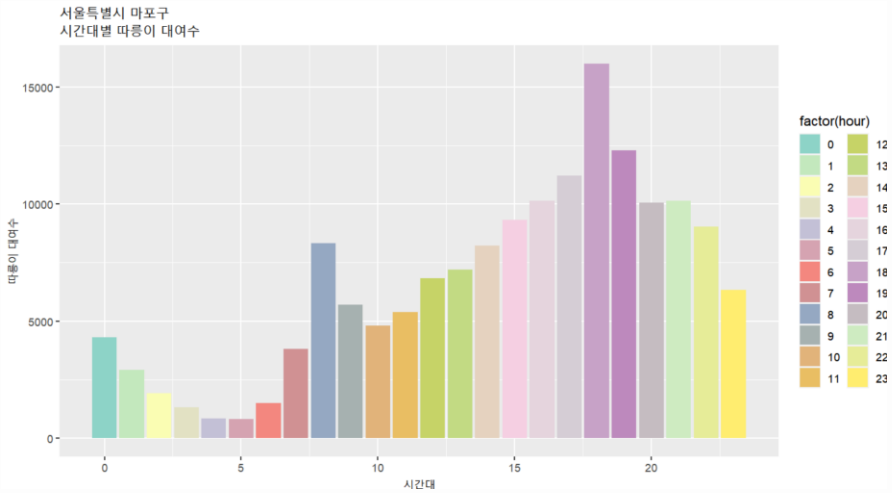

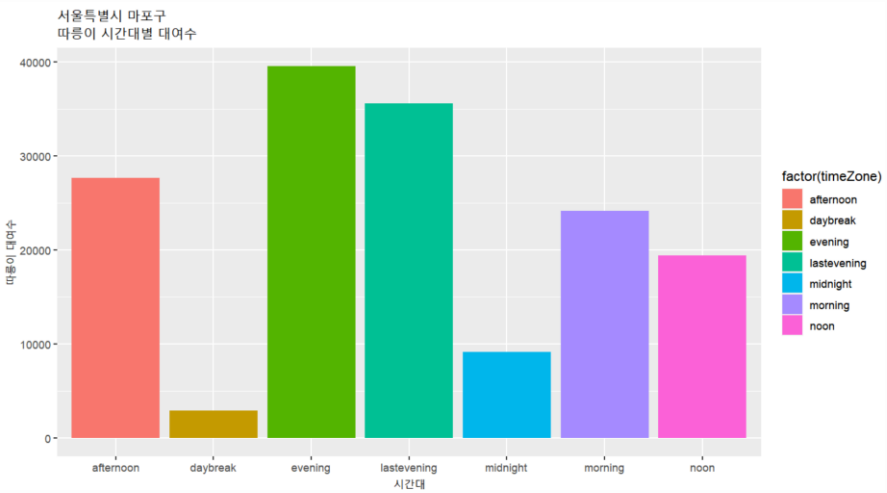

	timeZone	mean.count	count	sum.count
	<fct>	<dbl>	<int>	<dbl>
1	evening	217.	182	39518
2	lastevening	146.	243	35564
3	afternoon	152.	182	27687
4	morning	79.2	305	24153
5	noon	107.	182	19417
6	midnight	50.1	182	9126
7	daybreak	16.0	183	2929

극단적 대기오염물질 농도 여부(atmosphere) 논리형 파생변수 생성

이상치가 자전거 대여수에 영향을 미치는지 예측 목적

```
> table(train$atomosphere)

general outlier
   1365      94
```

따릉이 데이터 시각화 EDA

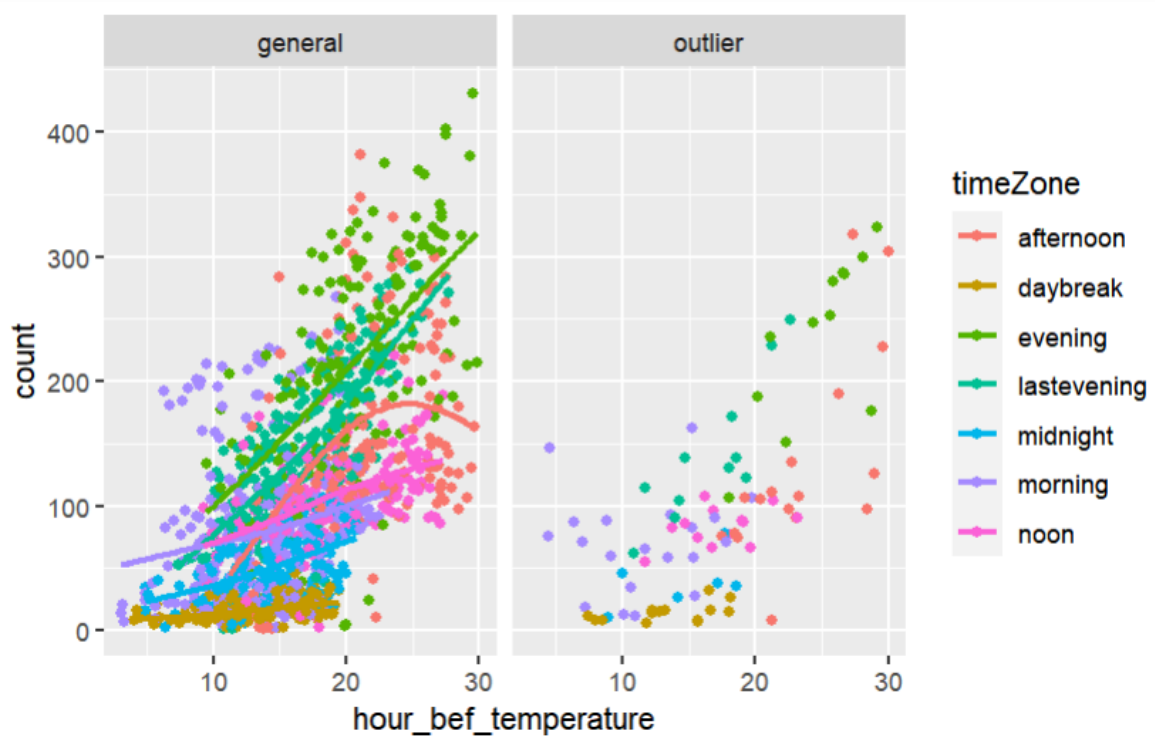

기온(가로축), 대여수(세로축),
시간대(범주)로 구성된 산점도를
대기오염지수 이상치 여부로 면 분할

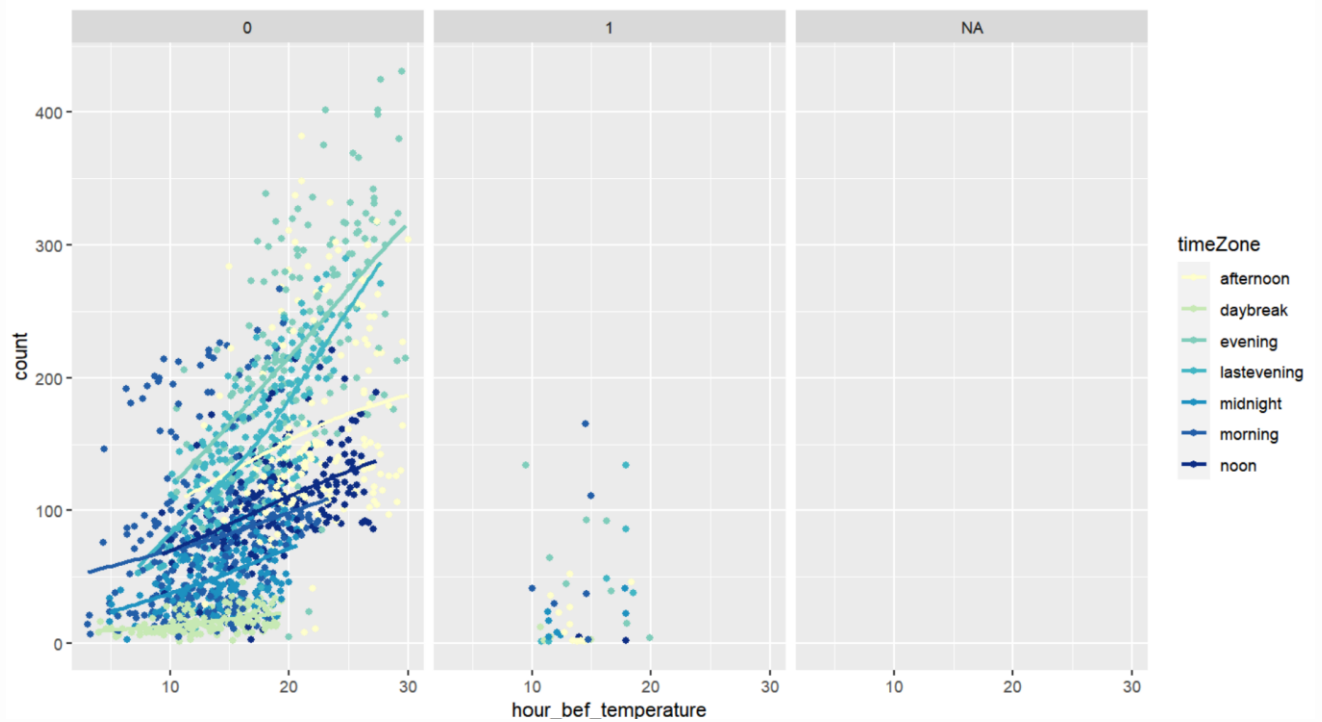

기온(가로축), 대여수(세로축),
시간대(범주)로 구성된 산점도를
비가 오는지 여부(0, 1)로 면 분할

서울특별시 마포구 따릉이 데이터 분석 목적

서울시민 따릉이 이용 → 시간, 위치 데이터 수집 → 이용권 결제대행 기업에 데이터 저장 → 데이터 분석 → 프로덕트 / BM 생산성 강화

만약 따릉이의 시공간 데이터 수집 기능을 데이터 비즈니스에 활용한다면

- 탄소발자국 감소를 측정하는 데이터 웨어러블 기기, 서울특별시 공공자전거 따릉이
- 신용카드회사, 결제대행기업 등 여신전문금융업계 內 마이데이터 인가 社의 고객에 대한 시공간, 소비, 거래, 생체 데이터 분석 및 활용
- 금융지주 그룹사의 경우 생명보험사에 대하여 데이터 거래하여 생태계 구축